

Авторские права

© Postgres Professional, 2019–2024

Авторы: Егор Рогов, Павел Лузанов, Павел Толмачев, Илья Баштанов Фото: Олег Бартунов (монастырь Пху и пик Бхрикути, Непал)

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Последовательное соединение хешированием: одно- и двухпроходное

Вычислительная сложность

Параллельное соединение хешированием: одно- и двухпроходное

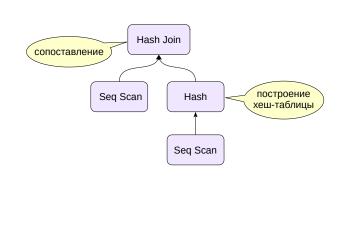
2

Хеш-соединение



По строкам одного набора строится хеш-таблица, строки другого набора сопоставляются с ней

Только эквисоединения



3

Основную идею хеширования мы рассмотрели в темах «Типы индексов» и «Группировка».

Для соединения хеширование применяется следующим образом. Сначала по одному из наборов в узле Hash строится хеш-таблица. Затем в узле Hash Join строки другого набора сопоставляются с построенной таблицей.

Как и хеш-индекс, хеш-соединение может работать только с условием равенства: хеш-функция не сохраняет порядок значений.

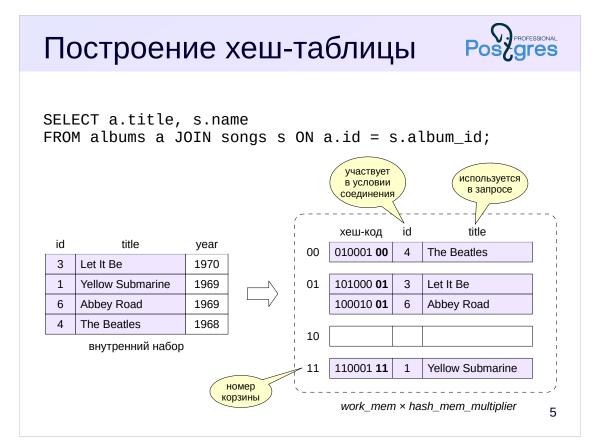
Рассмотрим на примере, как происходит соединение.

Однопроходное соединение Postgres



Применяется, когда для хеш-таблицы достаточно оперативной памяти

4



Первым этапом в памяти строится хеш-таблица.

Строки первого (внутреннего) набора читаются последовательно, и для каждой из них вычисляется хеш-функция от значений полей, входящих в условие соединения (в нашем примере это числовые идентификаторы id).

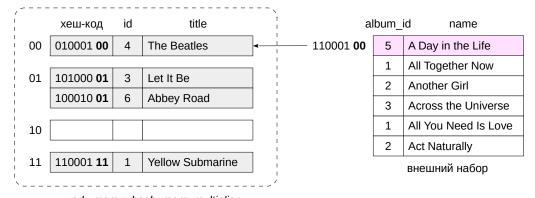
В корзину хеш-таблицы помещаются вычисленный хеш-код и все поля, которые входят в условие соединения или используются в запросе.

Размер хеш-таблицы в памяти ограничен значением work_mem × hash_mem_multiplier. Наилучшая эффективность достигается, если вся хеш-таблица помещается в этот объем памяти целиком. Поэтому планировщик обычно обычно выбирает в качестве внутреннего меньший из двух наборов строк. Также стоит не использовать в запросе лишние поля, в том числе «звездочку», чтобы не перегружать хештаблицу ненужной информацией.

Сопоставление



SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album_id;



work_mem × hash_mem_multiplier

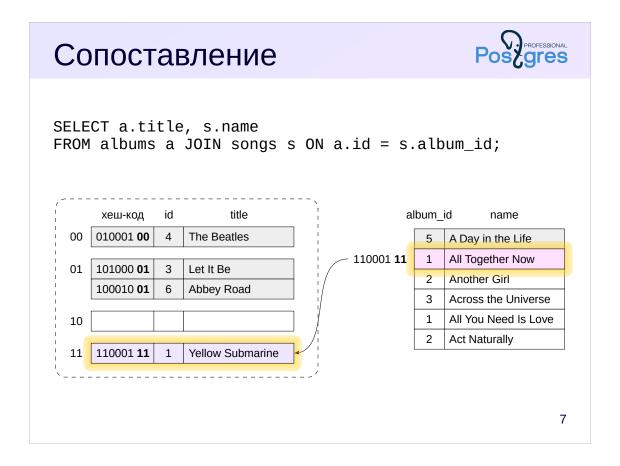
6

На втором этапе мы последовательно читаем второй набор строк. По мере чтения мы вычисляем хеш-функцию от значений полей, участвующих в условии соединения. Если в соответствующей корзине хеш-таблицы обнаруживается строка

- 1) с таким же хеш-кодом,
- и со значениями полей, подходящими под условие соединения, то мы нашли пару.

Проверки одного только хеш-кода недостаточно. Во-первых, не все условия соединения, перечисленные в запросе, могут быть учтены при выполнении соединения хешированием (поддерживаются только эквисоединения). Во-вторых, возможны коллизии, при которых разные значения получат одинаковые хеш-коды (вероятность этого мала, но тем не менее она есть).

В нашем примере для первой строки соответствия нет.



Вторая строка второго набора дает соответствие, которое уже можно вернуть вышестоящему узлу плана: («Yellow Submarine», «All Together Now»).



Для третьей строки соответствия нет (соответствующая корзина хештаблицы пуста).



Для четвертой получаем соответствие («Let It Be», «Across the Universe»).

Заметим, что в корзине хеш-таблицы оказалось две строки первого набора, и их придется просмотреть обе.



Для пятой строки получаем соответствие («Yellow Submarine», «All You Need Is Love»).



Для шестой строки соответствия нет. На этом работа соединения завершена.

Исходный код алгоритма можно найти в файле src/backend/executor/nodeHashjoin.c

Однопроходное соединение хешированием

При низкой селективности оптимизатор предпочитает соединение хешированием:

Узел Hash Join начинает работу с того, что обращается к дочернему узлу Hash. Тот получает от своего дочернего узла (здесь — Seq Scan) весь набор строк и строит хеш-таблицу.

Затем Hash Join обращается ко второму дочернему узлу и соединяет строки, постепенно возвращая полученные результаты.

Проверим, как выполняется этот запрос:

Хеш-таблица поместилась в память (Batches: 1). Параметр Buckets показывает число корзин в хеш-таблице, а Memory Usage — объем использованной оперативной памяти.

Обратите внимание, что хеш-таблица строилась по меньшему набору строк.

Модификации Hash Join включают уже рассмотренные ранее Left, Semi и Anti, а также Right для правого и Full для полного соединений:

QUERY PLAN

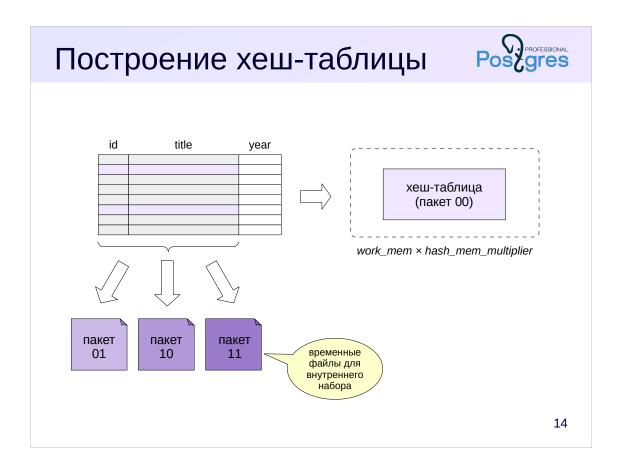
Обратите внимание, что независимо от того, в каком порядке перечислены таблицы в соединении, хеш-таблица строится по меньшему набору.

Двухпроходное соединение Postgres



Применяется, когда хеш-таблица не помещается в оперативную память: наборы данных разбиваются на пакеты и последовательно соединяются

13

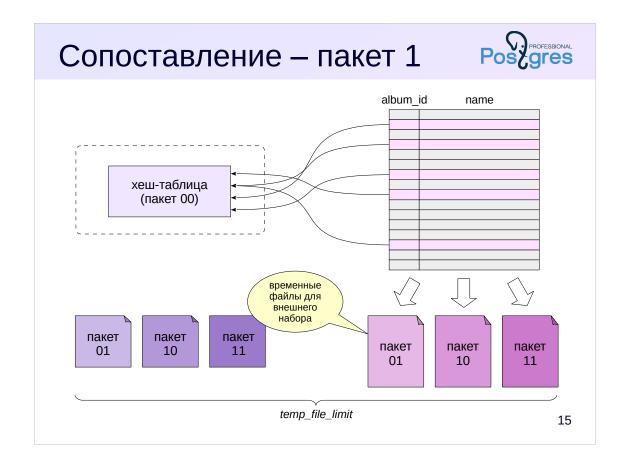


Если хеш-таблица не помещается в объем памяти, ограниченный work_mem × hash_mem_multiplier, первый (внутренний) набор строк разбивается на отдельные пакеты. Для распределения по пакетам используется некоторое количество битов хеш-кода, поэтому число пакетов всегда является степенью числа 2. В идеале в каждый пакет попадает примерно одинаковое количество строк, но, если значения в строках повторяются, возможен перекос.

При планировании запроса заранее вычисляется минимально необходимое число пакетов так, чтобы хеш-таблица для каждого пакета помещалась в памяти. Это число не уменьшается, даже если оптимизатор ошибся с оценками, но при необходимости может динамически увеличиваться.

Хеш-таблица для первого пакета остается в памяти, а строки, принадлежащие другим пакетам, сбрасываются на диск во временные файлы — каждый пакет в свой файл.

На рисунке показано четыре пакета.

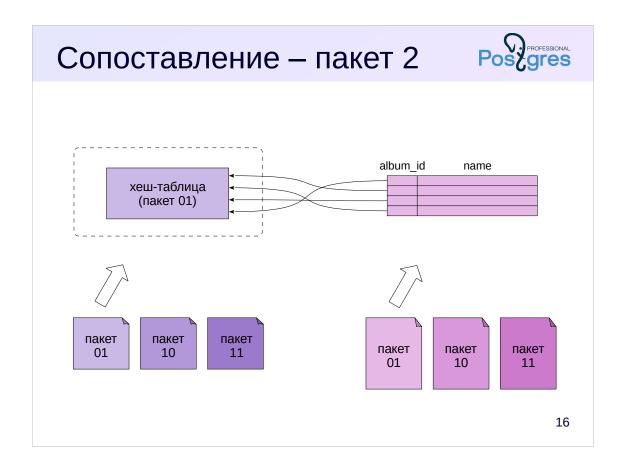


Далее читается второй (внешний) набор строк. Если строка принадлежит первому пакету, она сопоставляется с хеш-таблицей, которая как раз содержит первый пакет. С другими пакетами строку сопоставлять не надо — в них не может найтись соответствие, поскольку хеш-коды заведомо будут отличаться.

Если строка принадлежит другому пакету, она сбрасывается на диск — опять же, каждый пакет в свой временный файл.

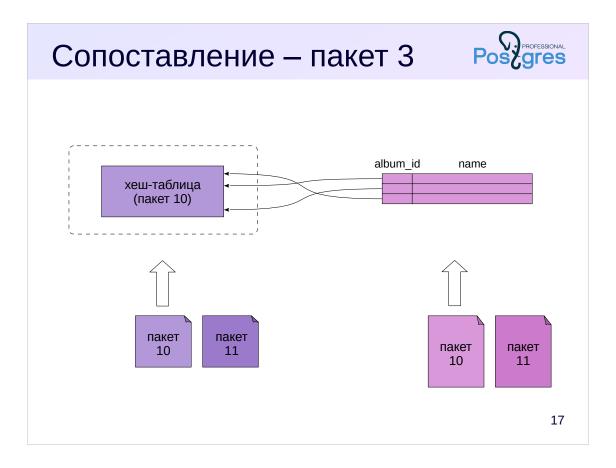
Таким образом, при *N* пакетах используются 2(*N*–1) файлов.

Следует учитывать, что использование временных файлов на диске ограничивается параметром *temp_file_limit*, который определяет общий предел дисковой памяти для сеанса. (Буферы временных таблиц в это ограничение не входят.)

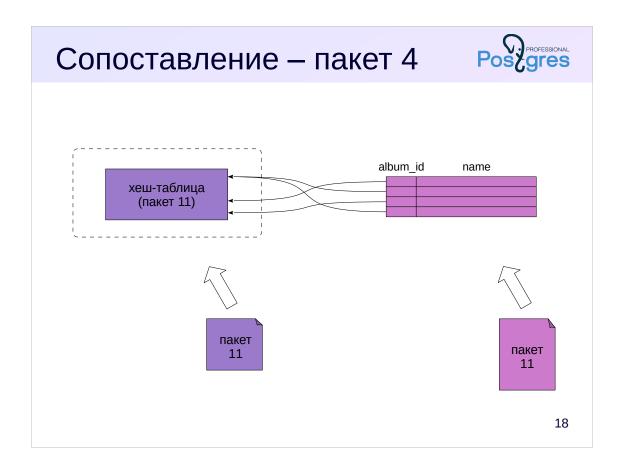


Далее по очереди обрабатываются все пакеты, начиная со второго. Из временного файла в хеш-таблицу считываются строки внутреннего набора, затем из другого временного файла считываются строки внешнего набора и сопоставляются с хеш-таблицей.

Процедура повторяется для всех оставшихся *N*–1 пакетов. На рисунке показано соединение для второго пакета (01).



На рисунке показано соединение для третьего пакета (10).



После обработки последнего пакета соединение завершено и временные файлы освобождены.

Таким образом, при нехватке оперативной памяти алгоритм соединения становится двухпроходным: каждый пакет (кроме первого) требуется записать на диск и затем прочитать повторно. Разумеется, это сказывается на эффективности соединения. Поэтому важно, чтобы:

- в хеш-таблицу попадали только действительно нужные поля (обязанность автора запроса),
- хеш-таблица строилась по меньшему набору строк (обязанность планировщика).

Двухпроходное соединение хешированием

Возьмем теперь большие таблицы и выведем статистику использования буферного кеша:

```
=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)
SELECT *
FROM bookings b
 JOIN tickets t ON b.book_ref = t.book_ref;
                          QUERY PLAN
______
Hash Join (actual rows=2949857 loops=1)
  Hash Cond: (t.book_ref = b.book_ref)
  Buffers: shared hit=64 read=62798, temp read=54218 written=54218
  -> Seq Scan on tickets t (actual rows=2949857 loops=1)
        Buffers: shared hit=32 read=49383
  -> Hash (actual rows=2111110 loops=1)
        Buckets: 131072 Batches: 32 Memory Usage: 4551kB
        Buffers: shared hit=32 read=13415, temp written=10701
        -> Seq Scan on bookings b (actual rows=2111110 loops=1)
             Buffers: shared hit=32 read=13415
Planning:
  Buffers: shared hit=99 read=7 dirtied=1
(12 rows)
```

Теперь хеш-таблица не поместилась в память и используется двухпроходное соединение. Потребовалось 32 пакета (Batches).

Видно, что узел Hash записывает пакеты во временные файлы (temp written), а узел Hash Join и записывает, и читает (temp read и written).

Сравним с таким же запросом, который выводит только одно поле:

Расход памяти уменьшился, так как в хеш-таблице теперь только одно поле (вместо трех), и количество пакетов уменьшилось вдвое.

Вычислительная сложность Postgres



 $\sim N + M$, где

N и M — число строк в первом и втором наборах данных

Начальные затраты на построение хеш-таблицы Эффективно для большого числа строк

20

Общая сложность соединения хешированием пропорциональна сумме числа строк в одном и другом наборах данных. Поэтому метод соединения хешированием гораздо эффективнее вложенного цикла при большом числе строк.

Однако, чтобы начать соединение, требуется построить хеш-таблицу: из-за этого при небольшом числе строк вложенный цикл более эффективен.

Соединение хешированием (в сочетании с полным сканированием таблиц) характерно для OLAP-запросов, в которых надо обработать большое число строк, причем общая пропускная способность важнее времени отклика.

Стоимость хеш-соединения

Начальная стоимость узла Hash Join складывается из стоимостей:

- получения всего первого набора данных (здесь билеты);
- построения хеш-таблицы пока таблица не готова, соединение не может начаться.

Можно обратить внимание на то, что в узле Hash стоимость построения хеш-таблицы не отражена.

Полная стоимость добавляет к начальной следующие стоимости:

- получения всего второго набора данных (здесь перелеты);
- проверки по хеш-таблице;
- обращения к диску в случае, когда предполагается использование более одного пакета.

Главный вывод: стоимость хеш-соединения пропорциональна N+M, где N и M — число строк в соединяемых наборах данных. При больших N и M это значительно выгоднее, чем произведение в случае соединения вложенным циклом.



В отличие от других способов соединения, хеш-соединение не только может участвовать в параллельных планах, но и имеет отдельный эффективный алгоритм работы. Этот алгоритм позволяет параллельно выполнять оба этапа соединения: и построение хеш-таблицы по первому (внутреннему) набору строк, и сопоставление с ней строк второго (внешнего) набора.

Возможность параллельного хеш-соединения управляется параметром *enable_parallel_hash*; по умолчанию параметр включен.

Как и у последовательного алгоритма, у параллельного есть два варианта: однопроходный при достаточном количестве оперативной памяти и двухпроходный.

Начнем с однопроходного варианта.

Параллельно, один проход Post gres



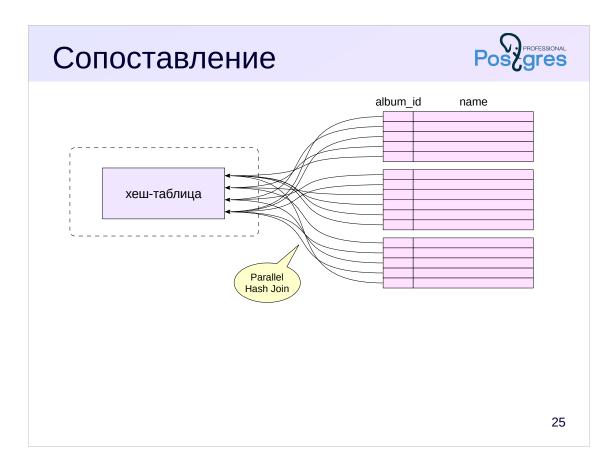
Процессы используют общую хеш-таблицу

23



Однопроходный алгоритм используется, если хеш-таблица помещается в *суммарный* объем памяти, выделенный всем участвующим в соединении процессам, то есть размер хеш-таблицы ограничен значением *work mem × hash mem multiplier ×* количество процессов.

Процессы параллельно читают первый набор строк (например, используя узел Parallel Seq Scan) и строят общую хеш-таблицу в разделяемой памяти, где каждый из них имеет к ней доступ.



После того, как хеш-таблица полностью построена, рабочие процессы приступают к параллельному чтению второго набора и сопоставляют прочитанные ими строки с общей-хеш-таблицей. Таким образом, каждый из процессов проверяет по хеш-таблице только часть данных.

Однопроходное параллельное хеш-соединение

Увеличим объем памяти, выделяемый процессу для построения хеш-таблицы:

```
=> SET work_mem = '32MB';
SET
Выполним запрос с агрегацией:
=> EXPLAIN (analyze, costs off, timing off, summary off)
SELECT count(*)
FROM bookings b
 JOIN tickets t ON b.book_ref = t.book_ref;
                                         QUERY PLAN
Finalize Aggregate (actual rows=1 loops=1)
   -> Gather (actual rows=3 loops=1)
        Workers Planned: 2
        Workers Launched: 2
         -> Partial Aggregate (actual rows=1 loops=3)
               -> Parallel Hash Join (actual rows=983286 loops=3)
                    Hash Cond: (t.book_ref = b.book_ref)
                     -> Parallel Seq Scan on tickets t (actual rows=983286 loops=3)
                     -> Parallel Hash (actual rows=703703 loops=3)
                          Buckets: 4194304 Batches: 1 Memory Usage: 115392kB
                           -> Parallel Seq Scan on bookings b (actual rows=703703
loops=3)
(11 rows)
```

Обратите внимание на использование памяти (Memory Usage): объем превышает ограничение, установленное для одного рабочего процесса ($64MB = work_mem \times hash_mem_multiplier$), но в общую память трех процессов хештаблица помещается. Поэтому выполняется однопроходное соединение (Batches: 1).

Параллельно, два прохода Postgres



Наборы строк разбиваются на пакеты, которые затем параллельно обрабатываются рабочими процессами

27



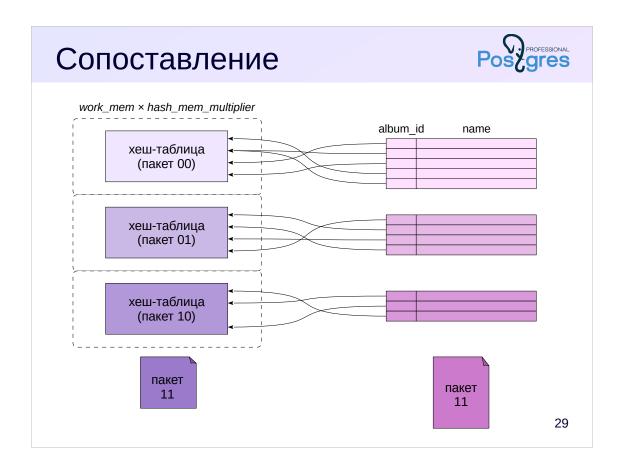
Хеш-таблица может не поместиться в объем памяти, ограниченный work_mem × hash_mem_multiplier × количество процессов, причем это может выясниться и на этапе выполнения соединения. В этом случае используется двухпроходный алгоритм, который существенно отличается и от двухпроходного последовательного, и от однопроходного параллельного.

Сначала рабочие процессы параллельно читают первый набор данных, разбивают его на пакеты и записывают пакеты во временные файлы. Первый пакет тоже попадает в файл; хеш-таблица в памяти не строится.

Обратите внимание, что каждый процесс записывает строки во все временные файлы; запись синхронизируется.

Затем рабочие процессы параллельно читают второй набор данных и также разбивают его на пакеты и записывают во временные файлы.

Таким образом, при *N* пакетах на диск записываются 2*N* файлов.

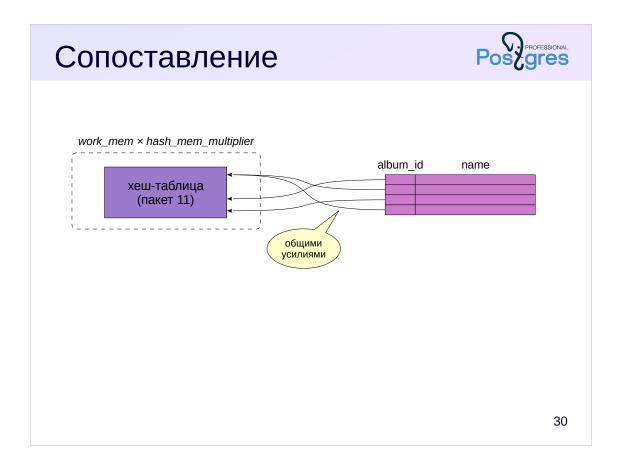


Затем каждый рабочий процесс выбирает себе по одному пакету.

Процесс загружает первый набор выбранного пакета в хеш-таблицу в памяти. В этом алгоритме у каждого процесса своя хеш-таблица размером work_mem × hash_mem_multiplier, но располагаются они в общей памяти, то есть доступ к каждой таблице есть у всех рабочих процессов.

После заполнения хеш-таблицы процесс читает второй набор выбранного пакета и сопоставляет строки.

Когда процесс завершает обработку одного пакета, он выбирает следующий, еще не обработанный.



Когда необработанные пакеты заканчиваются, освободившийся процесс подключается к обработке одного из еще не завершенных пакетов, пользуясь тем, что все хеш-таблицы находятся в разделяемой памяти.

Несколько хеш-таблиц работают лучше, чем одна большая: в этом случае проще организовать совместную работу и меньше ресурсов тратится на синхронизацию.

Двухпроходное параллельное хеш-соединение

```
Теперь уменьшим объем памяти:
=> SET work_mem = '16MB';
SET
Выполним тот же запрос с агрегацией:
=> EXPLAIN (analyze, costs off, timing off, summary off)
SELECT count(*)
FROM bookings b
 JOIN tickets t ON b.book_ref = t.book_ref;
                                         QUERY PLAN
 Finalize Aggregate (actual rows=1 loops=1)
   -> Gather (actual rows=3 loops=1)
        Workers Planned: 2
        Workers Launched: 2
         -> Partial Aggregate (actual rows=1 loops=3)
               -> Parallel Hash Join (actual rows=983286 loops=3)
                     Hash Cond: (t.book_ref = b.book_ref)
                     -> Parallel Seq Scan on tickets t (actual rows=983286 loops=3)
                     -> Parallel Hash (actual rows=703703 loops=3)
                           Buckets: 1048576 Batches: 4 Memory Usage: 28896kB
                           -> Parallel Seq Scan on bookings b (actual rows=703703
loops=3)
(11 rows)
```

Соединение стало двухпроходным с четырьмя пакетами.

Итоги



Соединение хешированием требует подготовки

надо построить хеш-таблицу

Эффективно для больших выборок

в том числе есть возможность параллельного соединения

Зависит от порядка соединения

внутренний набор должен быть меньше внешнего, чтобы минимизировать хеш-таблицу

Поддерживает только эквисоединения

для хеш-кодов операторы «больше» и «меньше» не имеют смысла

32

В отличие от соединения вложенным циклом, хеш-соединение требует подготовки: построения хеш-таблицы. Пока таблица не построена, ни одна результирующая строка не может быть получена.

Зато соединение хешированием эффективно работает на больших объемах данных. Оба набора строк читаются последовательно и только один раз (два раза в случае нехватки оперативной памяти).

Ограничением соединения хеширования является поддержка только эквисоединений. Дело в том, что хеш-значения можно сравнивать только на равенство, операции «больше» и «меньше» просто не имеют смысла.

Практика



- 1. Напишите запрос, показывающий занятые места в салоне для всех рейсов.
 - Какой способ соединения выбрал планировщик? Проверьте, хватило ли оперативной памяти для размещения хеш-таблиц.
- 2. Измените запрос, чтобы он выводил только общее количество занятых мест. Как изменился план запроса? Почему планировщик не использовал аналогичный план для предыдущего запроса?
- 3. Напишите запрос, показывающий имена пассажиров и номера рейсов, которыми они следуют. Разберитесь по плану запроса, в какой последовательности выполняются операции.

33

- 1. Для этого достаточно соединить рейсы (flights) с посадочными талонами (boarding_passes).
- 3. Такой запрос должен соединять три таблицы: билеты (tickets), перелеты (ticket flights) и рейсы (flights).

1. Список занятых мест

FROM flights f

JOIN boarding passes bp ON bp.flight_id = f.flight_id;

```
=> EXPLAIN SELECT f.flight_no, bp.seat_no
FROM flights f
 JOIN boarding_passes bp ON bp.flight_id = f.flight_id;
                                  OUERY PLAN
Hash Join (cost=8508.51..229844.17 rows=7925644 width=10)
  Hash Cond: (bp.flight id = f.flight id)
  -> Seq Scan on boarding_passes bp (cost=0.00..137560.44 rows=7925644 width=7)
  -> Hash (cost=4772.67..4772.67 rows=214867 width=11)
        -> Seq Scan on flights f (cost=0.00..4772.67 rows=214867 width=11)
(5 rows)
Использовано соединение хешированием.
=> EXPLAIN (analyze, costs off, timing off, summary off)
SELECT f.flight_no, bp.seat_no
FROM flights f
 JOIN boarding_passes bp ON bp.flight_id = f.flight_id;
                           OUERY PLAN
-----
Hash Join (actual rows=7925812 loops=1)
  Hash Cond: (bp.flight_id = f.flight_id)
  -> Seq Scan on boarding_passes bp (actual rows=7925812 loops=1)
  -> Hash (actual rows=214867 loops=1)
        Buckets: 262144 Batches: 2 Memory Usage: 6676kB
         -> Seq Scan on flights f (actual rows=214867 loops=1)
(6 rows)
Хеш-таблица не поместилась целиком в память, потребовалось два пакета.
2. Количество занятых мест
=> EXPLAIN SELECT count(*)
FROM flights f
 JOIN boarding passes bp ON bp.flight_id = f.flight_id;
                                               QUERY PLAN
Finalize Aggregate (cost=114720.28..114720.29 rows=1 width=8)
   -> Gather (cost=114720.06..114720.27 rows=2 width=8)
        Workers Planned: 2
        -> Partial Aggregate (cost=113720.06..113720.07 rows=1 width=8)
              -> Parallel Hash Join (cost=5467.82..105464.18 rows=3302352 width=0)
                    Hash Cond: (bp.flight_id = f.flight_id)
                    -> Parallel Seq Scan on boarding passes bp (cost=0.00..91327.52
rows=3302352 width=4)
                    -> Parallel Hash (cost=3887.92..3887.92 rows=126392 width=4)
                          -> Parallel Seg Scan on flights f (cost=0.00..3887.92
rows=126392 width=4)
(9 rows)
Здесь планировщик использовал параллельный план. В предыдущем запросе это не было оправдано из-за высокой
стоимости пересылки данных между процессами, а в данном случае передается только одно число.
=> EXPLAIN (analyze, costs off, timing off, summary off)
SELECT count(*)
```

```
Finalize Aggregate (actual rows=1 loops=1)

-> Gather (actual rows=3 loops=1)

Workers Planned: 2

Workers Launched: 2

-> Partial Aggregate (actual rows=1 loops=3)

-> Parallel Hash Join (actual rows=2641937 loops=3)

Hash Cond: (bp.flight_id = f.flight_id)

-> Parallel Seq Scan on boarding_passes bp (actual rows=2641937 loops=3)

-> Parallel Hash (actual rows=71622 loops=3)

Buckets: 262144 Batches: 1 Memory Usage: 10496kB

-> Parallel Seq Scan on flights f (actual rows=71622 loops=3)

(11 rows)
```

Обратите внимание на поле loops в узлах выше и ниже Gather- оно соответствует реальному числу процессов, работавших над запросом.

3. Пассажиры и номера рейсов

```
=> EXPLAIN (costs off)
SELECT t.passenger_name, f.flight_no
FROM tickets t
 JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
 JOIN flights f ON f.flight_id = tf.flight_id;
                  QUERY PLAN
Hash Join
  Hash Cond: (tf.flight_id = f.flight_id)
  -> Hash Join
        Hash Cond: (tf.ticket no = t.ticket no)
         -> Seq Scan on ticket_flights tf
         -> Hash
              -> Seq Scan on tickets t
  -> Hash
         -> Seg Scan on flights f
(9 rows)
```

Сначала выполняется соединение билетов (tickets) с перелетами (ticket_flights), причем хеш-таблица строится по таблице билетов.

Затем рейсы (flights) соединяются с результатом первого соединения; хеш-таблица строится по таблице рейсов.