

## Авторские права

© Postgres Professional, 2019–2024

Авторы: Егор Рогов, Павел Лузанов, Павел Толмачев, Илья Баштанов Фото: Олег Бартунов (монастырь Пху и пик Бхрикути, Непал)

## Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

## Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

## Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

# Темы



Алгоритм соединения слиянием

Вычислительная сложность

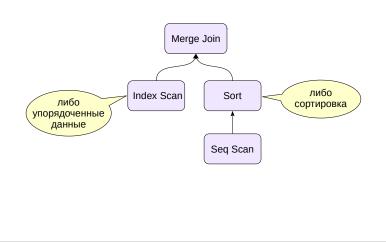
Соединение слиянием в параллельных планах

2

## Соединение слиянием



Слияние двух отсортированных наборов строк Результат соединения автоматически отсортирован



3

Третий, и последний, способ соединения — соединение слиянием.

Идея этого способа состоит в том, что два предварительно отсортированных набора данных нетрудно объединить в один общий — и точно так же отсортированный — набор. Похожим образом работает узел Gather Merge.

Подготовительным этапом для соединения слиянием служит сортировка обоих наборов строк. Сортировка — дорогая операция, она имеет сложность O(N log N).

Но иногда этого этапа удается избежать, если можно сразу получить отсортированные по нужным столбцам наборы строк, например, за счет индексного доступа к таблице.



Само слияние устроено просто. Сначала берем первые строки обоих наборов и сравниваем их между собой. В данном случае мы сразу нашли соответствие и можем вернуть первую строку результата: («Yellow Submarine», «All Together Now»).

Общий алгоритм таков: читаем следующую строку того набора, для которого значение поля, по которому происходит соединение, меньше (один набор «догоняет» другой). Если же значения одинаковы, как в нашем примере, то читаем следующую строку второго (внутреннего) набора.



Вновь соответствие: («Yellow Submarine», «All You Need Is Love»). Снова читаем следующую строку второго набора.



В данном случае соответствия нет.

Поскольку 1 < 2, читаем следующую строку первого набора.



## Соответствия нет.

3 > 2, поэтому читаем следующую строку второго набора.



Снова нет соответствия, снова 3 > 2, снова читаем строку второго набора.



Есть соответствие: («Let It Be», «Across the Universe»). 3 = 3, читаем следующую строку второго набора.

## Слияние SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album\_id; id title album id year name Yellow Submarine All Together Now 1969 1 3 Let It Be 1970 1 All You Need Is Love The Beatles 1968 Another Girl Abbey Road 1969 Act Naturally 3 Across the Universe A Day in the Life 10

## Соответствия нет.

3 < 5, читаем строку первого набора.

### Слияние SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album\_id; id title album id year name Yellow Submarine All Together Now 1969 1 3 Let It Be 1970 1 All You Need Is Love The Beatles 1968 Another Girl 4 Abbey Road 1969 2 Act Naturally 3 Across the Universe A Day in the Life 11

## Соответствия нет.

4 < 5, читаем строку первого набора.



И последний шаг: снова нет соответствия.

На этом соединение слиянием окончено.

На самом деле алгоритм сложнее — если в первом (внешнем) наборе строк встречается несколько одинаковых значений, нужно иметь возможность перечитать строки второго (внутреннего) набора с тем же ключом соединения.

Псевдокод алгоритма можно посмотреть в файле <a href="mailto:src/backend/executor/nodeMergejoin.c">src/backend/executor/nodeMergejoin.c</a>.

Важно, что алгоритм слияния возвращает результат соединения в отсортированном виде. В частности, полученный набор строк можно использовать для следующего соединения слиянием без дополнительной сортировки.

#### Соединение слиянием

Если результат необходим в отсортированном виде, оптимизатор может предпочесть соединение слиянием. Особенно, если данные от дочерних узлов можно получить уже отсортированными — как в этом примере:

```
=> EXPLAIN (costs off) SELECT *
FROM tickets t
  JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
ORDER BY t.ticket no;
                           OUFRY PLAN
Merae Join
   Merge Cond: (t.ticket no = tf.ticket no)
   -> Index Scan using tickets_pkey on tickets t
   -> Index Scan using ticket_flights_pkey on ticket_flights tf
(4 rows)
Вот еще один пример с двумя соединениями слиянием, в котором один узел Merge Join получает отсортированный
набор от другого узла Merge Join:
=> EXPLAIN (costs off) SELECT t.ticket_no, bp.flight_id, bp.seat_no
FROM tickets t
  JOIN ticket_flights tf ON t.ticket_no = tf.ticket_no
  JOIN boarding passes bp ON bp.ticket_no = tf.ticket_no
   AND bp.flight_id = tf.flight_id
ORDER BY t.ticket_no;
                                       QUERY PLAN
-----
Merge Join
  Merge Cond: (tf.ticket_no = t.ticket_no)
   -> Merge Join
         Merge Cond: ((tf.ticket no = bp.ticket no) AND (tf.flight id = bp.flight id))
         Index Only Scan using ticket_flights_pkey on ticket_flights tfIndex Scan using boarding_passes_pkey on boarding_passes bp
```

Здесь соединяются перелеты (ticket\_flights) и посадочные талоны (boarding\_passes), и с этим, уже отсортированным по номерам билетов, набором строк соединяются билеты (tickets).

Для Merge Join также существуют модификации Left, Right, Semi, Anti и Full.

-> Index Only Scan using tickets pkey on tickets t

(7 rows)

В настоящее время соединение слиянием поддерживает только эквисоединения, соединения по операциям «больше» или «меньше» не реализованы.

Таким образом, модификация Full существует только для соединений хешированием и слиянием, и оба варианта работают только с условием равенства. Если пренебречь производительностью, полное соединение можно получить, объединив результаты левого соединения и антисоединения — таким вариантом придется воспользоваться, если потребуется полное соединение по иному условию.

# Вычислительная сложность Poskgres



 $\sim N + M$ , где

N и M — число строк в первом и втором наборах данных, если не требуется сортировка

 $\sim N \log N + M \log M$ , если сортировка нужна

Возможные начальные затраты на сортировку Эффективно для большого числа строк

14

В случае, когда не требуется сортировать данные, общая сложность соединения слиянием пропорциональна сумме числа строк в обоих наборах данных. Но, в отличие от соединения хешированием, здесь не требуются накладные расходы на построение хеш-таблицы.

Поэтому соединение слиянием может успешно применяться как в OLTP-, так и в OLAP-запросах.

Однако если сортировка требуется, то стоимость становится пропорциональной произведению количества строк на логарифм этого количества, и на больших объемах такой способ скорее всего проиграет соединению хешированием.

#### Вычислительная сложность

```
Посмотрим на стоимость соединения слиянием:
```

```
=> EXPLAIN SELECT *
FROM tickets t
    JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
ORDER BY t.ticket_no;

QUERY PLAN

Merge Join (cost=0.99..822524.10 rows=8392681 width=136)
    Merge Cond: (t.ticket_no = tf.ticket_no)
    -> Index Scan using tickets_pkey on tickets t (cost=0.43..139115.26 rows=2950184 width=104)
    -> Index Scan using ticket_flights_pkey on ticket_flights tf (cost=0.56..571124.87 rows=8392681 width=32)
```

Начальная стоимость включает:

(4 rows)

- сумму начальных стоимостей дочерних узлов (включает стоимость сортировки, если она необходима);
- стоимость получения первой пары строк, соответствующих друг другу.

.....

Полная стоимость добавляет к начальной:

- сумму стоимостей получения обоих наборов данных;
- стоимость сравнения строк.

Общий вывод: стоимость соединения слиянием пропорциональна N+M (где N и M — число соединяемых строк), если не требуется отдельная сортировка. Сортировка набора из K строк добавляет K оценке как минимум  $K \times \log(K)$ .

В отличие от соединения хешированием, слияние без сортировки хорошо подходит для случая, когда надо быстро получить первые строки.

```
=> EXPLAIN SELECT *
FROM tickets t
    JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
ORDER BY t.ticket_no
LIMIT 1000;
```

QUERY PLAN

```
Limit (cost=0.99..98.99 rows=1000 width=136)

-> Merge Join (cost=0.99..822524.10 rows=8392681 width=136)

Merge Cond: (t.ticket_no = tf.ticket_no)

-> Index Scan using tickets_pkey on tickets t (cost=0.43..139115.26 rows=2950184 width=104)

-> Index Scan using ticket_flights_pkey on ticket_flights tf (cost=0.56..571124.87 rows=8392681 width=32) (5 rows)
```

Обратите внимание и на то, как уменьшилась общая стоимость.

## В параллельных планах Внешний набор строк сканируется параллельно, внутренний — последовательно каждым процессом Gather Merge Join Merge Join Merge Join Parallel Parallel Parallel Sort Sort Sort Index Scan Index Scan Index Scan Seq Scan Seq Scan Seq Scan

Соединение слиянием может использоваться в параллельных планах.

16

Так же, как и при соединении вложенным циклом, сканирование одного набора строк выполняется рабочими процессами параллельно, но другой набор строк каждый рабочий процесс читает полностью самостоятельно. Поэтому при соединении больших объемов строк в параллельных планах гораздо чаще используется соединение хешированием, имеющее эффективный параллельный алгоритм.

### В параллельных планах SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album\_id; id title year Yellow Submarine 1969 album\_id name 1 All Together Now 1 All You Need Is Love Let It Be 1970 2 Another Girl The Beatles 1968 2 Act Naturally 3 Across the Universe 6 Abbey Road 1969 A Day in the Life Parallel Index Scan 17

Внутренний набор данных будет просканирован каждым из рабочих процессов от начала и до того момента, как станет понятно, что больше нет соответствий.

На этом слайде показаны строки, перебираемые первым процессом.



Второй процесс просканирует весь набор и найдет одно соответствие.

## В параллельных планах SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album\_id; id title year Yellow Submarine 1969 album\_id name All Together Now All You Need Is Love Let It Be 1970 Another Girl The Beatles 1968 Act Naturally Across the Universe 6 Abbey Road 1969 A Day in the Life 19

А третий процесс не обнаружит ни одного соответствия.

Конечно, все три процесса сканируют внутренний набор одновременно, а не по очереди.

## В параллельных планах

```
Нам потребуется индекс:
=> CREATE INDEX ON tickets(book_ref);
CREATE INDEX
Вот пример параллельного плана, в котором используется соединение слиянием:
=> EXPLAIN (costs off)
SELECT count(*)
FROM bookings b
 JOIN (
   SELECT book_ref FROM tickets GROUP BY book_ref
) t ON b.book_ref = t.book_ref;
                                QUERY PLAN
------
Finalize Aggregate
  -> Gather
       Workers Planned: 2
       -> Partial Aggregate
             -> Merge Join
                  Merge Cond: (b.book_ref = tickets.book_ref)
                  -> Parallel Index Only Scan using bookings_pkey on bookings b
                  -> Group
                       Group Key: tickets.book ref
                       -> Index Only Scan using tickets_book_ref_idx on tickets
(10 rows)
```

Здесь индекс на таблице бронирований bookings\_pkey сканируется параллельно, а результат группировки из подзапроса  $\mathbf{t}$  — каждым процессом полностью.

## Итоги



## Соединение слиянием может потребовать подготовки

надо отсортировать наборы строк или получить их заранее отсортированными

## Эффективно для больших выборок

хорошо, если наборы уже отсортированы хорошо, если нужен отсортированный результат

Не зависит от порядка соединения

Поддерживает только эквисоединения

другие не реализованы, но принципиальных ограничений нет

21

Чтобы начать соединение слиянием, оба набора строк должны быть отсортированы. Хорошо, если удается получить данные уже в нужном порядке; если нет — требуется выполнить сортировку.

Само слияние выполняется очень эффективно даже для больших наборов строк. В качестве приятного бонуса результирующая выборка тоже упорядочена, поэтому такой способ соединения привлекателен, если вышестоящим узлам плана также требуется сортировка (например, запрос с фразой ORDER BY или еще одна сортировка слиянием).

Итак, в распоряжении планировщика есть три способа соединения: вложенный цикл, хеширование и слияние (не считая различных модификаций). Для каждого способа есть ситуации, в которых он оказывается более эффективным, чем остальные. Это позволяет планировщику выбрать именно тот способ, который — как предполагается — лучше подойдет в каждом конкретном случае. А точность предположений напрямую зависит от имеющейся статистики.

## Практика



1. Проверьте план выполнения запроса, показывающего все места в салонах в порядке кодов самолетов:

```
SELECT * FROM aircrafts a
  JOIN seats s ON a.aircraft_code = s.aircraft_code
ORDER BY a.aircraft_code;
```

Но оформите его в виде курсора.

Уменьшите значение параметра *cursor\_tuple\_fraction* в десять раз. Как при этом изменился план выполнения?

2. Самолет можно заменить другим, если его вместимость отличается не более, чем на 20%. Получите таблицу замен между моделями Боинг и Аэробус, выполнив полное соединение. Как выполняется запрос?

22

2. Запрос, который нужно выполнить:

```
WITH cap AS (
    SELECT a.model, count(*)::numeric capacity
    FROM aircrafts a
        JOIN seats s ON a.aircraft_code = s.aircraft_code
    GROUP BY a.model
), a AS (
    SELECT * FROM cap WHERE model LIKE 'Aəpoбус%'
), b AS (
    SELECT * FROM cap WHERE model LIKE 'БОИНГ%'
)
SELECT a.model AS airbus, b.model AS boeing
FROM a FULL JOIN b
    ON b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
ORDER BY 1,2;
```

### 1. Параметр cursor tuple fraction

=> EXPLAIN DECLARE c CURSOR FOR SELECT \*

План выполнения курсора:

```
FROM aircrafts a
 JOIN seats s ON a.aircraft_code = s.aircraft_code
ORDER BY a.aircraft_code;
                                   QUERY PLAN
-----
Merge Join (cost=1.51..420.71 rows=1339 width=55)
  Merge Cond: (s.aircraft_code = ml.aircraft_code)
  -> Index Scan using seats pkey on seats s (cost=0.28..64.60 rows=1339 width=15)
  -> Sort (cost=1.23..1.26 rows=9 width=72)
        Sort Key: ml.aircraft_code
        -> Seq Scan on aircrafts_data ml (cost=0.00..1.09 rows=9 width=72)
(6 rows)
Текущее значение cursor_tuple_fraction:
=> SHOW cursor_tuple_fraction;
cursor_tuple_fraction
0.1
(1 row)
Уменьшим его:
=> SET cursor_tuple_fraction = 0.01;
SET
=> EXPLAIN DECLARE c CURSOR FOR SELECT *
FROM aircrafts a
 JOIN seats s ON a.aircraft_code = s.aircraft_code
ORDER BY a.aircraft_code;
                                         QUERY PLAN
Merge Join (cost=0.41..431.73 rows=1339 width=55)
  Merge Cond: (ml.aircraft_code = s.aircraft_code)
   -> Index Scan using aircrafts pkey on aircrafts data ml (cost=0.14..12.27 rows=9
width=72)
  -> Index Scan using seats pkey on seats s (cost=0.28..64.60 rows=1339 width=15)
(4 rows)
Теперь планировщик выбирает другой план: его начальная стоимость ниже (хотя общая стоимость, наоборот, выше).
2. Полное соединение
```

Попробуем выполнить запрос.

```
=> WITH cap AS (
   SELECT a.model, count(*)::numeric capacity
    FROM aircrafts a
     JOIN seats s ON a.aircraft code = s.aircraft code
   GROUP BY a.model
), a AS (
    SELECT * FROM cap WHERE model LIKE 'Aəpo6yc%'
), b AS (
    SELECT * FROM cap WHERE model LIKE 'Боинг%'
SELECT a.model AS airbus, b.model AS boeing
FROM a FULL JOIN b
 ON b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
ORDER BY 1,2;
```

ERROR: FULL JOIN is only supported with merge-joinable or hash-joinable join conditions

Получаем ошибку: полное соединение реализовано только для условия равенства, поскольку только вложенный цикл поддерживает соединение по произвольному условию, но зато не поддерживает полное соединение.

Обойти ограничение можно, объединив результаты левого внешнего соединения и антисоединения:

```
=> WITH cap AS (
    SELECT a.model, count(*)::numeric capacity
    FROM aircrafts a
     JOIN seats s ON a.aircraft code = s.aircraft code
   GROUP BY a.model
), a AS (
   SELECT * FROM cap WHERE model LIKE 'Appobyc%'
), b AS (
   SELECT * FROM cap WHERE model LIKE 'Боинг%'
SELECT a.model AS airbus, b.model AS boeing
FROM a LEFT JOIN b
 ON b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
UNION ALL
SELECT NULL, b.model
FROM b
WHERE NOT EXISTS (
 SELECT 1
 FROM a
 WHERE b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
ORDER BY 1,2;
     airbus
                - 1
                      boeing
Аэробус А319-100 | Боинг 737-300
Аэробус А320-200 | Боинг 737-300
Аэробус А321-200 |
                  | Боинг 767-300
                  | Боинг 777-300
(5 rows)
План запроса показывает, что соединения выполняются методом вложенного цикла:
=> EXPLAIN (costs off)
WITH cap AS (
   SELECT a.model, count(*)::numeric capacity
   FROM aircrafts a
      JOIN seats s ON a.aircraft_code = s.aircraft_code
   GROUP BY a.model
), a AS (
   SELECT * FROM cap WHERE model LIKE 'Appobyc%'
), b AS (
   SELECT * FROM cap WHERE model LIKE 'Боинг%'
SELECT a.model AS airbus, b.model AS boeing
FROM a LEFT JOIN b
 ON b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
UNION ALL
SELECT NULL, b.model
FROM b
WHERE NOT EXISTS (
 SELECT 1
 WHERE b.capacity::numeric/a.capacity BETWEEN 0.8 AND 1.2
ORDER BY 1,2;
```

```
------
Sort
  Sort Key: a.model, b.model
  CTE cap
    -> HashAggregate
          Group Key: (ml.model ->> lang())
          -> Hash Join
               Hash Cond: (s.aircraft_code = ml.aircraft_code)
               -> Seq Scan on seats s
-> Hash
                     -> Seq Scan on aircrafts data ml
  CTE a
    -> CTE Scan on cap
          Filter: (model ~~ 'Aəpoбyc%'::text)
  CTE b
    -> CTE Scan on cap cap_1
          Filter: (model ~~ 'Боинг%'::text)
  -> Append
        -> Nested Loop Left Join
             Join Filter: (((b.capacity / a.capacity) >= 0.8) AND ((b.capacity /
a.capacity) <= 1.2))
             -> CTE Scan on a
             -> CTE Scan on b
        -> Nested Loop Anti Join
             Join Filter: (((b_1.capacity / a_1.capacity) >= 0.8) AND ((b_1.capacity / a_1.capacity / a_1.capacity))
a_1.capacity) <= 1.2))
             -> CTE Scan on b b_1
             -> CTE Scan on a a_1
(25 rows)
```